

23 | MySQL是怎么保证数据不丢的?

2019-01-04 林晓斌

MySQL实战45讲 进入课程 >



讲述:林晓斌

时长 17:00 大小 15.59M



今天这篇文章,我会继续和你介绍在业务高峰期临时提升性能的方法。从文章标题"MySQL 是怎么保证数据不丢的?",你就可以看出来,今天我和你介绍的方法,跟数据的可靠性有关。

在专栏前面文章和答疑篇中,我都着重介绍了 WAL 机制(你可以再回顾下<u>第 2 篇</u>、<u>第 9</u> 篇、<u>第 12 篇</u>和<u>第 15 篇</u>文章中的相关内容),得到的结论是:只要 redo log 和 binlog 保证持久化到磁盘,就能确保 MySQL 异常重启后,数据可以恢复。

评论区有同学又继续追问, redo log 的写入流程是怎么样的, 如何保证 redo log 真实地写入了磁盘。那么今天, 我们就再一起看看 MySQL 写入 binlog 和 redo log 的流程。

binlog 的写入机制

其实, binlog 的写入逻辑比较简单:事务执行过程中,先把日志写到 binlog cache,事务提交的时候,再把 binlog cache 写到 binlog 文件中。

一个事务的 binlog 是不能被拆开的,因此不论这个事务多大,也要确保一次性写入。这就涉及到了 binlog cache 的保存问题。

系统给 binlog cache 分配了一片内存,每个线程一个,参数 binlog_cache_size 用于控制单个线程内 binlog cache 所占内存的大小。如果超过了这个参数规定的大小,就要暂存到磁盘。

事务提交的时候,执行器把 binlog cache 里的完整事务写入到 binlog 中,并清空 binlog cache。状态如图 1 所示。



图 1 binlog 写盘状态

可以看到,每个线程有自己 binlog cache,但是共用同一份 binlog 文件。

图中的 write,指的就是指把日志写入到文件系统的 page cache,并没有把数据持久化到磁盘,所以速度比较快。

图中的 fsync, 才是将数据持久化到磁盘的操作。一般情况下, 我们认为 fsync 才占磁盘 的 IOPS。

write 和 fsync 的时机,是由参数 sync binlog 控制的:

- 1. sync binlog=0 的时候,表示每次提交事务都只 write,不 fsync;
- 2. sync binlog=1 的时候,表示每次提交事务都会执行 fsync;
- 3. sync binlog=N(N>1) 的时候,表示每次提交事务都 write,但累积 N 个事务后才 fsync.

因此,在出现 IO 瓶颈的场景里,将 sync binlog 设置成一个比较大的值,可以提升性能。 在实际的业务场景中,考虑到丢失日志量的可控性,一般不建议将这个参数设成0,比较常 见的是将其设置为 100~1000 中的某个数值。

但是,将 sync_binlog 设置为 N,对应的风险是:如果主机发生异常重启,会丢失最近 N 71614366 个事务的 binlog 日志。

redo log 的写》

接下来,我们再说说 redo log 的写入机制

在专栏的第15篇答疑文章中,我给你介绍了 redo log buffer。事务在执行过程中,生成 的 redo log 是要先写到 redo log buffer 的。

然后就有同学问了, redo log buffer 里面的内容, 是不是每次生成后都要直接持久化到磁 盘呢?

答案是,不需要。

如果事务执行期间 MySQL 发生异常重启,那这部分日志就丢了。由于事务并没有提交, 所以这时日志丢了也不会有损失。

那么,另外一个问题是,事务还没提交的时候,redo log buffer 中的部分日志有没有可能 被持久化到磁盘呢?

答案是,确实会有。

这个问题,要从 redo log 可能存在的三种状态说起。这三种状态,对应的就是图 2 中的三个颜色块。

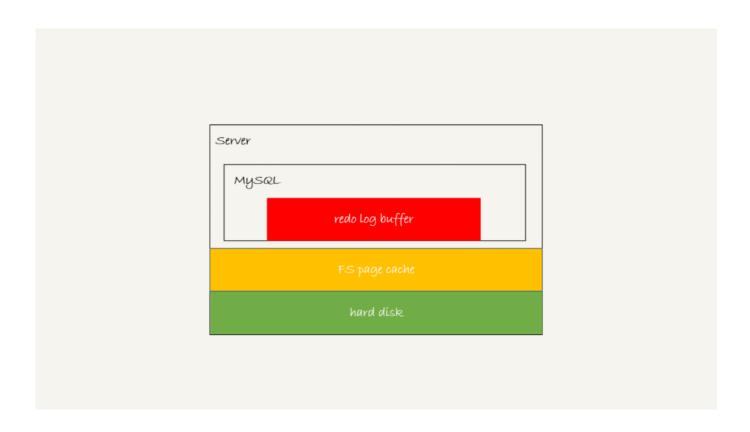


图 2 MySQL redo log 存储状态

这三种状态分别是:

- 1. 存在 redo log buffer 中,物理上是在 MySQL 进程内存中,就是图中的红色部分;
- 2. 写到磁盘 (write),但是没有持久化 (fsync),物理上是在文件系统的 page cache 里面,也就是图中的黄色部分;
- 3. 持久化到磁盘,对应的是 hard disk,也就是图中的绿色部分。

日志写到 redo log buffer 是很快的, wirte 到 page cache 也差不多,但是持久化到磁盘的速度就慢多了。

为了控制 redo log 的写入策略, InnoDB 提供了 innodb_flush_log_at_trx_commit 参数, 它有三种可能取值:

- 1. 设置为 0 的时候,表示每次事务提交时都只是把 redo log 留在 redo log buffer 中;
- 2. 设置为 1 的时候,表示每次事务提交时都将 redo log 直接持久化到磁盘;
- 3. 设置为 2 的时候,表示每次事务提交时都只是把 redo log 写到 page cache。

InnoDB 有一个后台线程,每隔 1 秒,就会把 redo log buffer 中的日志,调用 write 写到文件系统的 page cache,然后调用 fsync 持久化到磁盘。

注意,事务执行中间过程的 redo log 也是直接写在 redo log buffer 中的,这些 redo log 也会被后台线程一起持久化到磁盘。也就是说,一个没有提交的事务的 redo log,也是可能已经持久化到磁盘的。

实际上,除了后台线程每秒一次的轮询操作外,还有两种场景会让一个没有提交的事务的 redo log 写入到磁盘中。

- 1. 一种是, redo log buffer 占用的空间即将达到 innodb_log_buffer_size 一半的时候,后台线程会主动写盘。注意,由于这个事务并没有提交,所以这个写盘动作只是write,而没有调用 fsync,也就是只留在了文件系统的 page cache。
- 2. 另一种是,并行的事务提交的时候,顺带将这个事务的 redo log buffer 持久化到磁盘。假设一个事务 A 执行到一半,已经写了一些 redo log 到 buffer 中,这时候有另外一个线程的事务 B 提交,如果 innodb_flush_log_at_trx_commit 设置的是 1,那么按照这个参数的逻辑,事务 B 要把 redo log buffer 里的日志全部持久化到磁盘。这时候,就会带上事务 A 在 redo log buffer 里的日志一起持久化到磁盘。

这里需要说明的是,我们介绍两阶段提交的时候说过,时序上 redo log 先 prepare ,再写binlog,最后再把 redo log commit。

如果把 innodb_flush_log_at_trx_commit 设置成 1,那么 redo log 在 prepare 阶段就要持久化一次,因为有一个崩溃恢复逻辑是要依赖于 prepare 的 redo log,再加上 binlog来恢复的。(如果你印象有点儿模糊了,可以再回顾下<u>第 15 篇文章</u>中的相关内容)。

每秒一次后台轮询刷盘,再加上崩溃恢复这个逻辑,InnoDB 就认为 redo log 在 commit 的时候就不需要 fsync 了,只会 write 到文件系统的 page cache 中就够了。

通常我们说 MySQL 的"双 1"配置,指的就是 sync_binlog 和 innodb_flush_log_at_trx_commit 都设置成 1。也就是说,一个事务完整提交前,需要等 待两次刷盘,一次是 redo log (prepare 阶段) ,一次是 binlog。

这时候,你可能有一个疑问,这意味着我从 MySQL 看到的 TPS 是每秒两万的话,每秒就会写四万次磁盘。但是,我用工具测试出来,磁盘能力也就两万左右,怎么能实现两万的

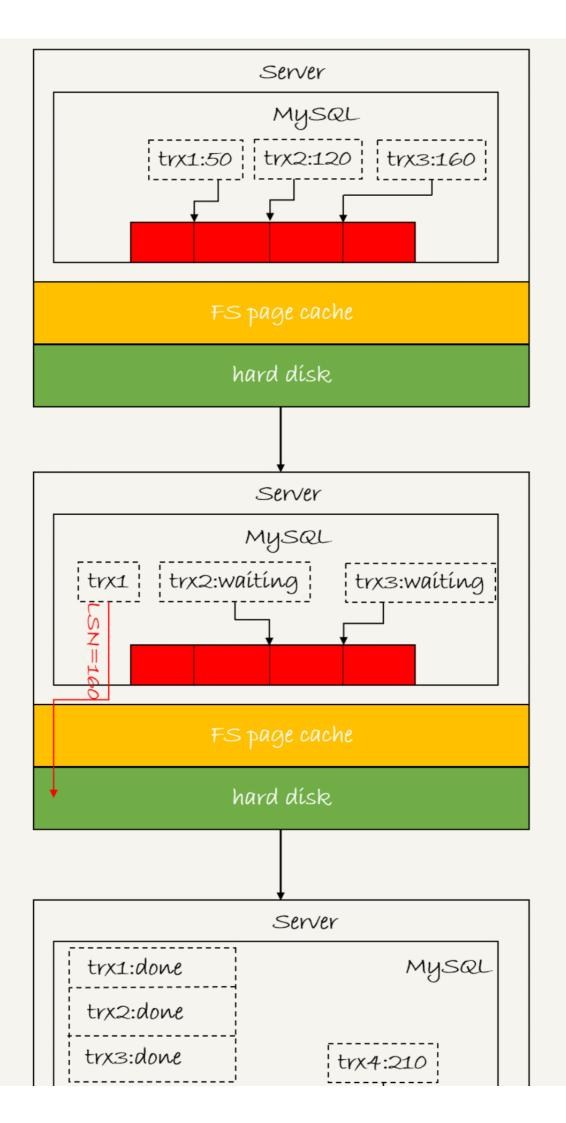
解释这个问题,就要用到组提交(group commit)机制了。

这里,我需要先和你介绍日志逻辑序列号(log sequence number, LSN)的概念。LSN 是单调递增的,用来对应 redo log 的一个个写入点。每次写入长度为 length 的 redo log,LSN 的值就会加上 length。

LSN 也会写到 InnoDB 的数据页中,来确保数据页不会被多次执行重复的 redo log。关于 LSN 和 redo log、checkpoint 的关系,我会在后面的文章中详细展开。

如图 3 所示,是三个并发事务 (trx1, trx2, trx3) 在 prepare 阶段,都写完 redo log buffer,持久化到磁盘的过程,对应的 LSN 分别是 50、120 和 160。





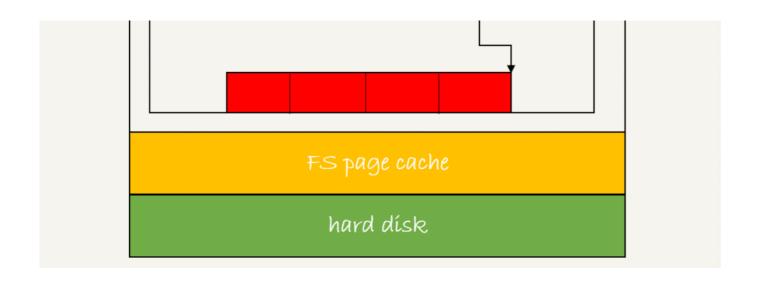


图 3 redo log 组提交

从图中可以看到,

- 1. trx1 是第一个到达的,会被选为这组的 leader;
- 2. 等 trx1 要开始写盘的时候,这个组里面已经有了三个事务,这时候 LSN 也变成了160;
- 3. trx1 去写盘的时候,带的就是 LSN=160,因此等 trx1 返回时,所有 LSN 小于等于 160 的 redo log,都已经被持久化到磁盘;
- 4. 这时候 trx2 和 trx3 就可以直接返回了。

所以,一次组提交里面,组员越多,节约磁盘 IOPS 的效果越好。但如果只有单线程压测,那就只能老老实实地一个事务对应一次持久化操作了。

在并发更新场景下,第一个事务写完 redo log buffer 以后,接下来这个 fsync 越晚调用,组员可能越多,节约 IOPS 的效果就越好。

为了让一次 fsync 带的组员更多,MySQL 有一个很有趣的优化:拖时间。在介绍两阶段提交的时候,我曾经给你画了一个图,现在我把它截过来。

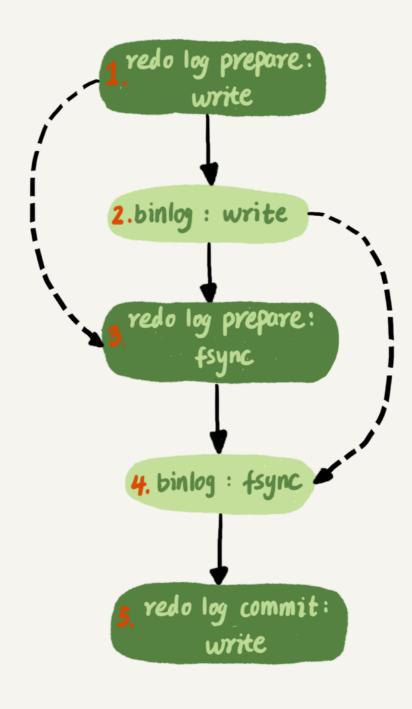


图 4 两阶段提交

图中, 我把"写 binlog"当成一个动作。但实际上, 写 binlog 是分成两步的:

- 1. 先把 binlog 从 binlog cache 中写到磁盘上的 binlog 文件;
- 2. 调用 fsync 持久化。

MySQL 为了让组提交的效果更好,把 redo log 做 fsync 的时间拖到了步骤 1 之后。也就是说,上面的图变成了这样:



这么一来, binlog 也可以组提交了。在执行图 5 中第 4 步把 binlog fsync 到磁盘时,如果有多个事务的 binlog 已经写完了,也是一起持久化的,这样也可以减少 IOPS 的消耗。

不过通常情况下第 3 步执行得会很快,所以 binlog 的 write 和 fsync 间的间隔时间短,导致能集合到一起持久化的 binlog 比较少,因此 binlog 的组提交的效果通常不如 redo log 的效果那么好。

如果你想提升 binlog 组提交的效果,可以通过设置 binlog_group_commit_sync_delay 和 binlog group commit sync no delay count 来实现。

- 1. binlog group commit sync delay 参数,表示延迟多少微秒后才调用 fsync;
- 2. binlog_group_commit_sync_no_delay_count 参数 , 表示累积多少次以后才调用 fsync。

这两个条件是或的关系,也就是说只要有一个满足条件就会调用 fsync。

所以,当 binlog_group_commit_sync_delay 设置为 0 的时候,binlog_group_commit_sync_no_delay_count 也无效了。

之前有同学在评论区问到,WAL 机制是减少磁盘写,可是每次提交事务都要写 redo log和 binlog,这磁盘读写次数也没变少呀?

现在你就能理解了, WAL 机制主要得益于两个方面:

- 1. redo log 和 binlog 都是顺序写,磁盘的顺序写比随机写速度要快;
- 2. 组提交机制,可以大幅度降低磁盘的 IOPS 消耗。

分析到这里,我们再来回答这个问题:**如果你的 MySQL 现在出现了性能瓶颈,而且瓶颈在 IO 上,可以通过哪些方法来提升性能呢?**

针对这个问题,可以考虑以下三种方法:

1. 设置 binlog_group_commit_sync_delay 和
binlog_group_commit_sync_no_delay_count 参数,减少 binlog 的写盘次数。这个

方法是基于"额外的故意等待"来实现的,因此可能会增加语句的响应时间,但没有丢失数据的风险。

- 2. 将 sync_binlog 设置为大于 1 的值(比较常见是 100~1000)。这样做的风险是, 主机 掉电时会丢 binlog 日志。
- 3. 将 innodb_flush_log_at_trx_commit 设置为 2。这样做的风险是, 主机掉电的时候会丢数据。

我不建议你把 innodb_flush_log_at_trx_commit 设置成 0。因为把这个参数设置成 0,表示 redo log 只保存在内存中,这样的话 MySQL 本身异常重启也会丢数据,风险太大。而 redo log 写到文件系统的 page cache 的速度也是很快的,所以将这个参数设置成 2 跟设置成 0 其实性能差不多,但这样做 MySQL 异常重启时就不会丢数据了,相比之下风险会更小。

小结

在专栏的第 2 篇和第 15 篇文章中,我和你分析了,如果 redo log 和 binlog 是完整的,MySQL 是如何保证 crash-safe 的。今天这篇文章,我着重和你介绍的是 MySQL 是"怎么保证 redo log 和 binlog 是完整的"。

希望这三篇文章串起来的内容,能够让你对 crash-safe 这个概念有更清晰的理解。

之前的第 15 篇答疑文章发布之后,有同学继续留言问到了一些跟日志相关的问题,这里为了方便你回顾、学习,我再集中回答一次这些问题。

问题 1: 执行一个 update 语句以后,我再去执行 hexdump 命令直接查看 ibd 文件内容,为什么没有看到数据有改变呢?

回答:这可能是因为 WAL 机制的原因。update 语句执行完成后, InnoDB 只保证写完了 redo log、内存,可能还没来得及将数据写到磁盘。

问题 2:为什么 binlog cache 是每个线程自己维护的,而 redo log buffer 是全局共用的?

回答: MySQL 这么设计的主要原因是, binlog 是不能"被打断的"。一个事务的 binlog 必须连续写, 因此要整个事务完成后, 再一起写到文件里。

而 redo log 并没有这个要求,中间有生成的日志可以写到 redo log buffer 中。redo log buffer 中的内容还能"搭便车",其他事务提交的时候可以被一起写到磁盘中。

问题 3:事务执行期间,还没到提交阶段,如果发生 crash 的话,redo log 肯定丢了,这会不会导致主备不一致呢?

回答:不会。因为这时候 binlog 也还在 binlog cache 里,没发给备库。crash 以后 redo log 和 binlog 都没有了,从业务角度看这个事务也没有提交,所以数据是一致的。

问题 4:如果 binlog 写完盘以后发生 crash,这时候还没给客户端答复就重启了。等客户端再重连进来,发现事务已经提交成功了,这是不是 bug?

回答:不是。

你可以设想一下更极端的情况,整个事务都提交成功了, redo log commit 完成了, 备库 也收到 binlog 并执行了。但是主库和客户端网络断开了,导致事务成功的包返回不回去,这时候客户端也会收到"网络断开"的异常。这种也只能算是事务成功的,不能认为是 bug。

实际上数据库的 crash-safe 保证的是:

- 1. 如果客户端收到事务成功的消息,事务就一定持久化了;
- 2. 如果客户端收到事务失败(比如主键冲突、回滚等)的消息,事务就一定失败了;
- 3. 如果客户端收到"执行异常"的消息,应用需要重连后通过查询当前状态来继续后续的逻辑。此时数据库只需要保证内部(数据和日志之间,主库和备库之间)一致就可以了。

最后,又到了课后问题时间。

今天我留给你的思考题是:你的生产库设置的是"双 1"吗?如果平时是的话,你有在什么场景下改成过"非双 1"吗?你的这个操作又是基于什么决定的?

另外,我们都知道这些设置可能有损,如果发生了异常,你的止损方案是什么?

你可以把你的理解或者经验写在留言区,我会在下一篇文章的末尾选取有趣的评论和你一起分享和分析。感谢你的收听,也欢迎你把这篇文章分享给更多的朋友一起阅读。

上期问题时间

我在上篇文章最后,想要你分享的是线上"救火"的经验。

@Long 同学,在留言中提到了几个很好的场景。

其中第 3 个问题 , "如果一个数据库是被客户端的压力打满导致无法响应的 , 重启数据库是没用的。" , 说明他很好地思考了。

这个问题是因为重启之后,业务请求还会再发。而且由于是重启,buffer pool 被清空,可能会导致语句执行得更慢。

他提到的第 4 个问题也很典型。有时候一个表上会出现多个单字段索引(而且往往这是因为运维工程师对索引原理不够清晰做的设计),这样就可能出现优化器选择索引合并算法的现象。但实际上,索引合并算法的效率并不好。而通过将其中的一个索引改成联合索引的方法,是一个很好的应对方案。

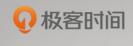
还有其他几个同学提到的问题场景,也很好,很值得你一看。

@Max 同学提到一个很好的例子:客户端程序的连接器,连接完成后会做一些诸如 show columns 的操作,在短连接模式下这个影响就非常大了。这个提醒我们,在 review 项目的时候,不止要 review 我们自己业务的代码,也要 review 连接器的行为。一般做法就是在测试环境,把 general_log 打开,用业务行为触发连接,然后通过 general log 分析连接器的行为。

@Manjusaka 同学的留言中,第二点提得非常好:如果你的数据库请求模式直接对应于客户请求,这往往是一个危险的设计。因为客户行为不可控,可能突然因为你们公司的一个运营推广,压力暴增,这样很容易把数据库打挂。

在设计模型里面设计一层,专门负责管理请求和数据库服务资源,对于比较重要和大流量的业务,是一个好的设计方向。

@Vincent 同学提了一个好问题,用文中提到的 DDL 方案,会导致 binlog 里面少了这个 DDL 语句,后续影响备份恢复的功能。由于需要另一个知识点



MySQL 实战 45讲

从原理到实战, 丁奇带你搞懂 MySQL

林晓斌 网络丁奇 前阿里资深技术专家



新版升级:点击「 🍫 请朋友读 」,10位好友免费读,邀请订阅更有 🚾 垒 奖励。

© 版权归极客邦科技所有,未经许可不得传播售卖。页面已增加防盗追踪,如有侵权极客邦将依法追究其法律责任。

上一篇 22 | MySQL有哪些"饮鸩止渴"提高性能的方法?

下一篇 24 | MySQL是怎么保证主备一致的?

精选留言 (70)

□写留言



心 7

老师好,有一个疑问:当设置sync_binlog=0时,每次commit都只时write到page cache,并不会fsync。但是做实验时binlog文件中还是会有记录,这是什么原因呢?是不是后台线程每秒一次的轮询也会将binlog cache持久化到磁盘?还是有其他的参数控制呢?

展开~

作者回复: 你看到的 "binlog的记录" ,也是从page cache读的哦。 Page cache是操作系统文件系统上的 ②



心 8

老师求解sync_binlog和binlog_group_commit_sync_no_delay_count这两个参数区别

如果

sync_binlog = N binlog_group_commit_sync_no_delay_count = M... 展开~

作者回复:好问题,我写这篇文章的时候也为了这个问题去翻了代码,是这样的: 达到N次以后,可以刷盘了,然后再进入(sync_delay和no_delay_count)这个逻辑;

Sync_delay如果很大,就达到no_delay_count才刷;

只要sync_binlog=0,也会有前面的等待逻辑,但是等完后还是不调fsync@

WilliamX 2019-01-04

ြ 5

为什么 binlog cache 是每个线程自己维护的,而 redo log buffer 是全局共用的?这个问题,感觉还有一点,binlog存储是以statement或者row格式存储的,而redo log是以page页格式存储的。page格式,天生就是共有的,而row格式,只跟当前事务相关展开~

作者回复: 嗯,这个解释也很好。 6

某、人 2019-01-06 心 4

有调到非双1的时候,在大促时非核心库和从库延迟较多的情况。 设置的是sync_binlog=0和innodb_flush_log_at_trx_commit=2 针对0和2,在mysql crash时不会出现异常,在主机挂了时,会有几种风险:

- 1.如果事务的binlog和redo log都还未fsync,则该事务数据丢失
- 2.如果事务binlog fsync成功,redo log未fsync,则该事务数据丢失。...

展开~

作者回复: 1. Write的时候只要写进去了, fsync其实很快的。连续性是write的时候做的(写的时候保证了连续)

2. 你的理解应该是对的。不是表级

alias cd=...

心 3

2019-01-28

事务A是当前事务,这时候事务B提交了。事务B的redolog持久化时候,会顺道把A产生的redolog也持久化,这时候A的redolog状态是prepare状态么?

展开~

作者回复: 不是。

说明一下哈,所谓的 redo log prepare,是"当前事务提交"的一个阶段,也就是说,在事务A 提交的时候,我们才会走到事务A的redo log prepare这个阶段。

事务A在提交前,有一部分redo log被事务B提前持久化,但是事务A还没有进入提交阶段,是无所谓"redo log prepare"的。

好问题

一大只急

2019-01-05

L 3

你是怎么验证的?等于0的时候虽然有走这个逻辑,但是最后调用fsync之前判断是0,就啥也没做就走了

回复老师:

老师,我说的sync_binlog=0或=1效果一样,就是看语句实际执行的效果,参数binlog_group_commit_sync_delay我设置成了500000微秒,在=1或=0时,对表进行...展开~

作者回复: 凸

非常好

然后再补上我回答的这个逻辑,就完备了

melon 2019-02-28

ඨ 2

老师帮忙看一下我binlog 组提交这块理解的对不对

binlog write 阶段

组里面第一个走到 binlog write 的事务记录一个时间戳,用于在 binlog fsync 阶段计算 sync delay了多少时间,姑且计为 start_time...

展开~

作者回复: 前面的伪代码不错哈

"binlog_group_commit_sync_no_delay_count这个参数是不是不应该设置的比并发线程数大",最好是这样的,否则的话,就只能等binlog group commit sync delay 时间到了

往事随风,... 2019-01-04

L 2

redolog 里面有已经提交事物日志,还有未提交事物日志都持久化到磁盘,此时异常重启, binlog 里面不是多余记录的未提交事物,干嘛不设计不添加未提交事物不更好

信信

2019-01-05

心 1

网上说binlog的写入顺序需要和InnoDB层事务提交顺序一致,否则通过xtrabackup这种物理备份工具进行备份时,会出现主备不一致。分析原因五花八门,感觉都不够准备,请老师指点。

作者回复: 我们文章中介绍的已经是演进过的版本,已经保证了写盘顺序,没有这个问题了哈

4

>



心 1

凸

凸

凸

主从模式下,内网从库如果设置双1,刚还原的数据发现根本追不上主库,所以从库设置了0,老师后面章节会讲关于mysql包括主从监控这块的内容吗。

展开٧

作者回复: 会讲到

Lane

2019-05-16

疑问:

老师说 设置 binlog_group_commit_sync_delay 和 binlog_group_commit_sync_no_delay_count 会导致延迟但是不会丢失。 这个参数是延迟fsync的时机,那么write后未fsync,宕机,不还是会丢吗?

展开٧



2019-05-11

老师, sync_binlog=N, N之间客户端已明确收到事务提交,而如果期间机器崩溃或掉电,重启会导致数据库数据也丢失或回滚,那不是客户端处理的数据可能也会有问题?比如账户类数据、银行转账等?望解惑!

liao xueq...

2019-05-06

老师好,这个问题,我想了很久,还是没能理解下面这句话,也给您就这个问题留了好几次言。

每秒一次后台轮询刷盘,再加上崩溃恢复这个逻辑,InnoDB就认为 redo log 在 commit 的时候就不需要fsync 了,只会 write 到文件系统的 page cache 中就够了。

•••

展开٧



ம

</l></l></l><

如果把sync_binlog设置为0, 那么就永远不会持久化到磁盘吗? 这样没问题吗? 但是我看评论里又说page cache也是文件系统, 那么就是放在磁盘的? 那还是变成写入到磁盘啊...... 展开 >



凸

Redolog的prepare阶段的fsync过程,不是已经把事务持久化到磁盘了吗?那么redolog的commit状态还有用吗?

展开٧



ß

每秒一次后台轮询刷盘,再加上崩溃恢复这个逻辑,InnoDB 就认为 redo log 在 commit 的时候就不需要 fsync 了,只会 write 到文件系统的 page cache 中就够了。

老师,这句话单独拎出来无法理解,重启服务器会丢1秒数据啊。这句话的前提是不是innodb_flush_log_at_trx_commit=1

展开~



心

老师,mgr环境还有必要设置双一吗?

展开~

作者回复: 要看你的ha策略哦

考虑数据可靠性,一般还是要的



凸

老师好,两阶段提交,redo log prepare阶段进行持久化,然后是binlog持久化,那么

commit阶段做了什么,又是如何判断redo log已经是两阶段完成了呢 展开~



Binlog的是不是组提交,和redo log的组提交有必然联系吗?这块没太明白。测试的时候 binlog里面的last_commited值有的相同有的不相同。如果last_commited值相同,是不 是意味着redo log里这几个事务也必须是组提交的呢

展开٧



Snake

Ď

2019-03-13

老师,请问文中说到的binlog_cache和redo_log_buffer是是针对一个数据库实例的,还是针对实际下具体某一个库的?如果针对是针对实例,那么有没有哪些配置或者机制是针对库的呢?